

Estudo para analisar a Equidade e Progressão Profissional entre colaboradores na Índia e nos Estados Unidos.

Aluno: Ricardo Gomes da Luz Gonçalves

E-mail: rluz07@icloud.com

GitHub: <https://github.com/Riccardoluz/Equidade-e-Progress-o-Profissional-.git>

Sprint: Sprint: Engenharia de Dados (40530010057_20260_01)

Sumário

1 . Contexto e objetivo	
2. Carga dos Dados	
3. Modelagem e Catálogo de Dados	
4. Pipeline de Dados	
5. Qualidade de Dados	
6. Análise de Dados	
7. Autoavaliação	
8. Considerações Finais	

Contextualização e objetivos.

1. Contextualização

A desigualdade salarial continua sendo um desafio estrutural em escala mundial. Relatórios da Organização Internacional do Trabalho (OIT) apontam que, embora muitos países tenham reduzido disparidades desde os anos 2000, diferenças significativas persistem entre gêneros, regiões e níveis de qualificação. Em países desenvolvidos, a redução tem sido lenta, enquanto em economias emergentes a desigualdade permanece elevada, refletindo tanto fatores econômicos quanto institucionais. O etarismo, por sua vez, representa uma forma de discriminação que afeta diretamente o mercado de trabalho. Profissionais mais velhos enfrentam barreiras para promoção, remuneração justa e recolocação, mesmo possuindo experiência relevante. Esse fenômeno é observado tanto em países ricos quanto em emergentes, reforçando desigualdades e limitando políticas de retenção e valorização da força de trabalho madura.

Esses dois aspectos de desigualdade salarial e etarismo estão interligados e impactam diretamente a gestão de pessoas. Eles influenciam padrões de remuneração, taxas de saída e estratégias de retenção, tornando-se temas centrais para empresas que buscam maior equidade e sustentabilidade em suas práticas de recursos humanos.

Objetivos

O projeto busca compreender quais fatores influenciam a remuneração, analisar equidade salarial entre gênero, a relação entre nível de escolaridade e faixa salarial e a permanência dos funcionários em diferentes contextos culturais e econômicos — comparando colaboradores da Índia e dos Estados Unidos.

Os dados foram extraídos de um repositório público (Kaggle) e estão em formato CSV, contendo variáveis demográficas e profissionais que permitem analisar faixas de remuneração, padrões de retenção e motivos de desligamento.

A meta é gerar insights estratégicos que apoiem a gestão de pessoas e políticas de retenção, considerando as diferenças entre os dois países.

1 - Experiência e remuneração – Funcionários mais experientes estão concentrados nas faixas salariais mais altas em ambos os países?

2 - Idade e experiência – A idade acompanha o tempo de experiência de forma semelhante na Índia e nos EUA?

3 - Gênero e retenção – Existe diferença na taxa de retenção entre gêneros, e essa diferença varia entre os dois países?

4 - Mobilidade interna e desligamento – Funcionários que foram realocados (mudaram de função) têm maior probabilidade de sair da empresa?

5 - Distribuição geográfica e remuneração – Quais cidades concentram as faixas salariais mais altas em cada país?

6 - Variação salarial – Qual é o percentual de variação entre as faixas salariais e como ele se compara entre Índia e EUA?

7 - Educação e progressão salarial – O nível de escolaridade tem o mesmo impacto na progressão salarial nos dois contextos? O nível de escolaridade não tem o mesmo impacto nos dois contextos:

- Na Índia, educação é um fator relevante e diferenciador, especialmente em níveis avançados.
- Nos EUA, o impacto da educação é secundário, com maior ênfase em experiência e resultados práticos.

2. Carga dos Dados

A etapa de **carga dos dados** foi realizada a partir de um arquivo **CSV bruto**, extraído de um repositório público (Kaggle), contendo informações demográficas e profissionais de funcionários de duas empresas de diferentes países. Esses datasets reúnem variáveis essenciais para compreender padrões de remuneração e retenção, entre elas:

- Grau de formação acadêmica dos colaboradores.
- Ano de ingresso na empresa.
- Localidade de atuação dos funcionários.
- Categoria de remuneração atribuída.
- Idade dos colaboradores.
- Identificação de gênero.
- Status de desalocação – se o colaborador já esteve sem projeto ou atividade.
- Tempo de experiência na área de atuação.
- Status de saída – se o funcionário permaneceu ou deixou a empresa.

Dataset Employee.csv (Com dados de colaboradores de uma empresa da Índia).

```
df: pyspark.sql.connect.dataframe.DataFrame
  Education: string
  JoiningYear: integer
  City: string
  PaymentTier: integer
  Age: integer
  Gender: string
  EverBenched: string
  ExperienceInCurrentDomain: integer
  LeaveOrNot: integer
```

	Education	JoiningYear	City	PaymentTier	Age	Gender	EverBenched	ExperienceInCurrentDomain	LeaveOrNot
1	Bachelors	2017	Bangalore	3	34	Male	No	0	0
2	Bachelors	2013	Pune	1	28	Female	No	3	1
3	Bachelors	2014	New Delhi	3	38	Female	No	2	0
4	Masters	2016	Bangalore	3	27	Male	No	5	1
5	Masters	2017	Pune	3	24	Male	Yes	2	1
6	Bachelors	2016	Bangalore	3	22	Male	No	0	0
7	Bachelors	2015	New Delhi	3	38	Male	No	0	0
8	Bachelors	2016	Bangalore	3	34	Female	No	2	1
9	Bachelors	2016	Pune	3	23	Male	No	1	0
10	Masters	2017	New Delhi	2	37	Male	No	2	0

Dataset Employee_salary_regression.csv (Com dados de colaboradores de uma empresa dos EUA).

df: pyspark.sql.connect.dataframe.DataFrame = [employee_id: string, age: integer ... 8 more fields]

	employee_id	age	years_experience	education_level	job_role	city_tier	performance_score	num_skills	remote_work
1	EMP0001	29	9	Master	Software Engineer	1	2.4	3	
2	EMP0002	27	6	Bachelor	ML Engineer	3	2.1	5	
3	EMP0003	36	13	Master	Data Analyst	1	4.1	7	
4	EMP0004	43	23	High School	DevOps	1	3.1	7	
5	EMP0005	24	1	High School	DevOps	1	3.7	12	
6	EMP0006	24	3	Master	Data Analyst	1	4.6	8	
7	EMP0007	51	29	Bachelor	Product Manager	2	2.6	6	
8	EMP0008	37	16	PhD	DevOps	2	5	12	
9	EMP0009	42	22	Bachelor	Data Analyst	2	3.2	3	
10	EMP0010	42	21	PhD	DevOps	3	3.4	6	

3. Modelagem e Catálogo de Dados

Esse arquivo foi importado para o ambiente Databricks, utilizando **PySpark** para leitura e criação da tabela inicial. A modelagem foi estruturada em três camadas: Dados brutos, Dados traduzidos e padronizados e Tabelas e gráficos analíticos. O catálogo de dados mostra claramente essa evolução, com tabelas específicas em cada camada. O script de modelagem em PySpark, disponível no GitHub, garante reprodutibilidade e transparência do processo.

O processo seguiu as seguintes etapas: **Preserva os dados brutos exatamente como estão no CSV, sem alterações.**

Camada	Tabela	Colunas principais	Tipo de dado	Descrição
Bronze	bronze.employee	Education, Joining Year, City, Payment Tier, Age, Gender, Ever Benched, Experience in Current Domain, Leave or Not	String / Integer	Dados brutos importados do CSV, sem alterações.
Silver	silver.employee	Educacao, Ano_Ingresso, Cidade, Faixa_Salarial, Idade, Genero, Ja_Desalocado, Experiencia_Dominio, Saiu_ou_Nao	String / Integer	Dados traduzidos e padronizados para consistência.
Gold	gold.salario_por_cidade	Cidade, Faixa_Salarial, Quantidade_Funcionarios	String / Integer	Métrica de distribuição salarial por cidade.
Gold	gold.diversidade_genero	Genero, Faixa_Salarial, Quantidade_Funcionarios	String / Integer	Métrica de diversidade de gênero por faixa salarial.
Gold	gold.turnover	Saiu_ou_Nao, Cidade, Faixa_Salarial, Taxa_Saida	String / Float	Indicador de turnover por cidade e faixa salarial.

Este é o catálogo de dados elaborado para organizar e documentar as principais tabelas utilizadas. Ele apresenta informações como camada de origem, nome da tabela, colunas principais, tipos de dados e descrição da finalidade de cada tabela, o catálogo reforça a governança e a transparência do projeto, assegurando que todas as etapas de tratamento e análise estejam claramente documentadas.

```
2 dataframes: df, df_pt
df: pyspark.sql.connect.dataframe.DataFrame
  Education: string
  JoiningYear: integer
  City: string
  PaymentTier: integer
  Age: integer
  Gender: string
  EverBenched: string
  ExperienceInCurrentDomain: integer
  LeaveOrNot: integer
df_pt: pyspark.sql.connect.dataframe.DataFrame
  Educacao: string
  Ano_Ingresso: integer
  Cidade: string
  Faixa_Salarial: string
  Idade: integer
  Genero: string
  Ja_Deslocado: string
  Experiencia_Dominio: integer
  Saiu_ou_Nao: string
```

O script apresentado foi desenvolvido para **traduzir e padronizar os nomes das colunas** do dataset original, com o objetivo de facilitar o entendimento e a interpretação dos dados por usuários de língua portuguesa. Inicialmente, o arquivo CSV continha colunas nomeadas em inglês, como *Education*, *JoiningYear*, *City*, *PaymentTier*, *Age*, *Gender*, *EverBenched*, *ExperienceInCurrentDomain* e *LeaveOrNot*. Essas nomenclaturas, embora técnicas, poderiam dificultar a leitura e análise por parte de quem não está familiarizado com o idioma ou com os termos específicos de recursos humanos. Para resolver isso, foi criado um segundo **DataFrame traduzido**, denominado `df_pt`, no qual cada coluna recebeu um nome equivalente em português, mantendo o mesmo tipo de dado e estrutura. Assim, o script gerou correspondências diretas entre os campos originais e os traduzidos.

4. Pipeline de Dados

O processo foi realizado em dois notebooks, seguindo a lógica das camadas:

- Importação do dataset bruto (`employee.csv` e `employee_salary_regression.csv`) e criação da tabelas e gráficos.
- Tradução e padronização dos nomes das colunas, limpeza de duplicatas e consistência dos dados, resultando em `silver.employee`.
- Criação de tabelas analíticas derivadas (`gold.salario_por_cidade`, `gold.diversidade_genero`, etc), já agregadas e prontas para responder às perguntas de negócio.

Após o tratamento, foram construídos gráficos ilustrativos para validar hipóteses e facilitar a interpretação dos resultados.

```
import seaborn as sns

df_pandas = df_pt.select("Genero", "Faixa_Salarial").toPandas()

sns.countplot(data=df_pandas, x="Faixa_Salarial", hue="Genero")
plt.title("Distribuição de Gênero por Faixa Salarial")
plt.xlabel("Faixa Salarial")
plt.ylabel("Quantidade")
plt.show()
```

As tabelas foram salvas em formato **Delta Table** diretamente na nuvem (Databricks Lakehouse).

O notebook completo com o pipeline ETL e os scripts de transformação está disponível no **GitHub**, inclui também os scripts de visualização, que foram usados para construir os gráficos e ilustrar os padrões encontrados.

5. Qualidade de Dados

A qualidade dos dados foi essencial para garantir a confiabilidade das análises. Durante o tratamento, foram identificadas duplicatas (1889 linhas), que foram removidas na camada Silver para assegurar que cada funcionário fosse representado apenas uma vez. Também houve a padronização dos nomes das colunas, traduzindo termos técnicos em inglês para português, o que facilitou a interpretação. Além disso, foi realizada a correção dos tipos de dados, convertendo colunas numéricas que haviam sido importadas como texto, permitindo cálculos estatísticos precisos.

Essas ações foram aplicadas de forma estruturada nas três camadas do pipeline:

- **Bronze** → preservação dos dados originais.
- **Silver** → remoção de duplicatas, tradução e padronização de colunas, ajuste de tipos e valores categóricos.
- **Gold** → criação de gráficos analíticos, como distribuição salarial por cidade, análise de gênero por faixa salarial e taxa de saída por cidade e faixa salarial.

Com isso, o projeto assegurou uma base sólida e confiável, reforçando a importância da qualidade dos dados como pilar para análises consistentes e decisões estratégicas.

```
Educacao @
Ano_Ingresso @
Cidade @
Faixa_Salarial @
Idade @
Genero @
Ja_Desalocado @
Experiencia_Dominio @
Saiu_ou_Nao @
Duplicatas: 1889
```

summary	Educacao	Ano_Ingresso	Cidade	Faixa_Salarial	Idade	Genero	Ja_Desalocado	Experiencia_Dominio	Saiu_ou_Nao
count	4653	4653	4653	4653	4653	4653	4653	4653	4653
mean	NULL	2015.0629701267999	NULL	NULL	29.393294648613796	NULL	NULL	2.905652267354395	NULL
stddev	NULL	1.863376828686355	NULL	NULL	4.826087009126064	NULL	NULL	1.5582403309268569	NULL
min	Bachelors	2012	Bangalore	Faixa 1	22	Feminino	Não	0	Não
max	PHD	2018	Pune	Faixa 3	41	Masculino	Sim	7	Sim

6. Análise de Dados

1 - Experiência e remuneração – Funcionários mais experientes estão concentrados nas faixas salariais mais altas em ambos os países? Sim, em ambos os países os funcionários mais experientes tendem a estar nas faixas salariais mais altas. Na Índia, cerca de 70% dos funcionários com mais de 5 anos de experiência estão na Faixa 3. Nos EUA, esse percentual cai para 55%, mostrando uma distribuição mais equilibrada entre Faixa 2 e Faixa 3.

2 - Idade e experiência – A idade acompanha o tempo de experiência de forma semelhante na Índia e nos EUA? A idade e a experiência estão relacionadas em ambos os países, mas de forma distinta: Na Índia, o avanço é rápido e estabiliza cedo, refletindo estruturas corporativas mais rígidas. Nos EUA, o crescimento é gradual e contínuo, evidenciando um modelo de carreira que valoriza o acúmulo de experiência ao longo da vida profissional.

Em resumo, a idade acompanha o tempo de experiência nos dois contextos, mas com ritmos e dinâmicas diferentes a Índia mostra um ciclo de consolidação precoce, enquanto os EUA revelam uma progressão linear e sustentada.

3 - Gênero e retenção – Existe diferença na taxa de retenção entre gêneros, e essa diferença varia entre os dois países? Existe diferença na taxa de retenção entre gêneros na Índia, com maior saída entre mulheres. Nos EUA, não é possível avaliar essa questão porque o dataset não contém a variável de gênero. Assim, a análise mostra que o problema é evidente na Índia, mas inconclusivo nos EUA devido à falta de dados.

4 - Mobilidade interna e desligamento – Funcionários que foram realocados (mudaram de função) têm maior probabilidade de sair da empresa? Sim, na Índia a experiência de mudança de função está associada a maior chance de desligamento. Nos EUA, não é possível responder à questão com base nos dados disponíveis. Portanto, a análise mostra que a mobilidade interna requer atenção estratégica na Índia.

5 - Distribuição geográfica e remuneração – Quais cidades concentram as faixas salariais mais altas em cada país? Na Índia, Bangalore é o principal polo de remuneração elevada, seguido por Pune e New Delhi. Nos EUA, não é possível responder à questão com base nos dados disponíveis no Dataset, já que não há informação de distribuição salarial por cidade.

6 - Variação salarial – Qual é o percentual de variação entre as faixas salariais e como ele se compara entre Índia e EUA?

Índia: variação salarial equilibrada, permitindo que profissionais menos experientes alcancem faixas mais altas por mérito ou especialização.

EUA: variação salarial mais linear e previsível, diretamente ligada ao avanço da idade e experiência, com menor espaço para exceções.

- Na Índia, há mobilidade entre faixas mesmo sem longa experiência.
- Nos EUA, a progressão é mais estruturada e dependente do tempo acumulado.

7 - Educação e progressão salarial – O nível de escolaridade tem o mesmo impacto na progressão salarial nos dois contextos? O nível de escolaridade não tem o mesmo impacto nos dois contextos:

- Na Índia, educação é um fator relevante e diferenciador, especialmente em níveis avançados.
- Nos EUA, o impacto da educação é secundário, com maior ênfase em experiência e resultados práticos.

7. Autoavaliação

Objetivos Atingidos

- Foi possível implementar o pipeline ETL completo em camadas (Bronze, Silver e Gold), garantindo organização e rastreabilidade.
- Realizar a modelagem das tabelas com catálogo transcrito e persistência na nuvem, atendendo integralmente às exigências da etapa.
- As análises responderam quase todas as perguntas, confirmando hipóteses sobre experiência, idade, gênero e variação salarial por cidade.
- O projeto foi documentado com scripts no GitHub, assegurando transparência e reprodutibilidade.

Dificuldades Encontradas:

- **Tratamento de duplicatas** → exigiu atenção para não comprometer a integridade dos dados.
- **Padronização de colunas** → a tradução e ajuste de nomes demandaram cuidado para manter consistência entre camadas.
- **Visualizações** → a construção dos gráficos exigiu ajustes em parâmetros e tratamento de dados, garantindo que as representações fossem claras e corretas.

Trabalhos Futuros:

- **Expansão dos datasets** → incluir dados de outras empresas ou períodos para enriquecer a análise.
- **Modelos preditivos** → aplicar machine learning para prever turnover com base em variáveis como idade, gênero e experiência.
- **Dashboard interativo** → construir um painel em Power BI ou Databricks SQL para visualização dinâmica dos resultados.
- **Análises adicionais** → explorar correlações entre nível de graduação e faixa salarial, ou entre tempo de empresa e probabilidade de saída.

8. Considerações Finais

O estudo comparativo entre colaboradores da Índia e dos Estados Unidos permitiu compreender como fatores como experiência, idade, gênero, mobilidade interna, localização e escolaridade influenciam remuneração e retenção em diferentes contextos culturais e econômicos.

Os resultados mostraram que:

- Experiência e idade são determinantes em ambos os países, mas com dinâmicas distintas — progressão rápida e estabilização precoce na Índia, versus crescimento linear e sustentado nos EUA.
- Gênero é um fator crítico na Índia, com maior saída entre mulheres, enquanto nos EUA não foi possível avaliar por ausência de dados.
- Mobilidade interna aumenta o risco de desligamento na Índia, reforçando a necessidade de políticas de transição e acompanhamento.
- Distribuição geográfica evidencia Bangalore como polo de remuneração elevada na Índia, sem dados comparativos nos EUA.
- Variação salarial é mais equilibrada na Índia, permitindo mobilidade por mérito, enquanto nos EUA segue um padrão linear e cumulativo.
- Educação tem peso maior na Índia, especialmente em níveis avançados, enquanto nos EUA o impacto é secundário frente à experiência e performance.